301002_Fernando_Ramacciotti_Quiz1_v2

June 1, 2017

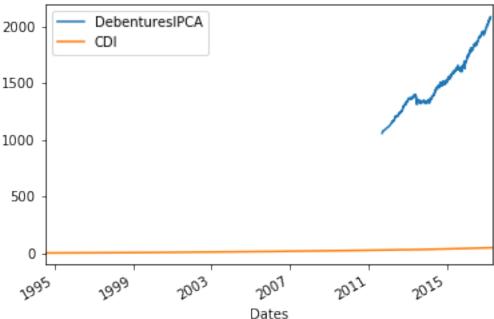
1 Econometria Séries Financeiras - Quiz I

1.1 Debentures atreladas ao IPCA

Fernando Martinelli Ramacciotti - 301002 fernandoramacciotti@gmail.com

```
In [1]: # importing libraries and source file
        %matplotlib inline
        import pandas as pd
        import os
        import numpy as np
        from scipy import stats
        import matplotlib.pyplot as plt
        import statsmodels.api as sm
        from statsmodels.graphics.api import qqplot
        pathname = os.getcwd()
        TimeSeriesXL = pd.ExcelFile(os.path.join(pathname, 'SeriesTemporaisHardcode
In [2]: # generating daily and monthly excess of return series
        # montlhy series
        AllAssetClasses = pd.DataFrame()
        for asset_class in TimeSeriesXL.sheet_names:
            #print (asset_class)
            df = TimeSeriesXL.parse(asset_class,index_col=0,skiprows=1)
            df.columns = [asset_class]
            df.index.name = 'Dates'
            AllAssetClasses = pd.concat([AllAssetClasses,df],join='outer',axis=1)
        AllAssetClasses.plot()
        AllAssetClasses = AllAssetClasses.resample('BM').last()
        Returns = AllAssetClasses.pct_change(1)
        EReturns = pd.DataFrame()
```

```
for asset_class in Returns.columns:
    EReturns[asset_class] = Returns[asset_class] - Returns['CDI']
EReturns = EReturns.drop('CDI', axis=1)
# daily series
AllAssetClasses_daily = pd.DataFrame()
for asset_class_daily in TimeSeriesXL.sheet_names:
    #print (asset_class_daily)
   df = TimeSeriesXL.parse(asset_class_daily, index_col=0, skiprows=1)
    df.columns = [asset_class_daily]
    df.index.name = 'Dates'
   AllAssetClasses_daily = pd.concat([AllAssetClasses_daily,df],join='oute
Returns_daily = AllAssetClasses_daily.pct_change(1)
EReturns_daily = pd.DataFrame()
for asset_class_daily in Returns.columns:
    EReturns_daily[asset_class_daily] = Returns_daily[asset_class_daily] -
EReturns_daily = EReturns_daily.drop('CDI', axis=1)
EReturns_daily = EReturns_daily.dropna()
          DebenturesIPCA
```



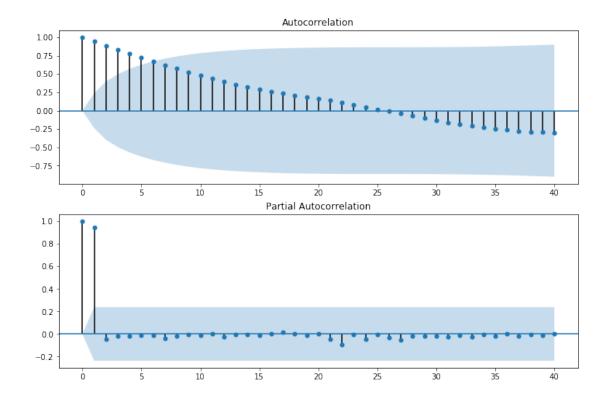
In [3]: EReturns.tail() # monthly

```
Out [3]:
                    DebenturesIPCA
        Dates
                           0.004777
        2016-12-30
        2017-01-31
                           0.004255
        2017-02-28
                           0.010822
        2017-03-31
                           0.006677
        2017-04-28
                          -0.000785
In [4]: EReturns_daily.tail() # "daily"
                    DebenturesIPCA
Out [4]:
        Dates
        2017-03-27
                           0.003757
        2017-03-30
                          -0.002192
        2017-04-04
                           0.001535
        2017-04-07
                           0.000054
        2017-04-11
                           0.000777
```

1.2 Fato 1 - FAC dos Preços decai linearmente e FACP truncada de ordem 1

Confirmado. A FAC decai suavemente, aparentemente com um ponto de inflexão próximo ao lag 25, e a FACP apresenta nos mostra que somente o primeiro lag é estatisticamente significante

```
In [5]: for asset_class in EReturns.columns:
    # Fato 1 - FAC decai linearmente, FACP só do lo lag
    TS_in_levels = AllAssetClasses[asset_class].dropna()
    fig = plt.figure(figsize=(12,8))
    ax1 = fig.add_subplot(211)
    fig = sm.graphics.tsa.plot_acf(TS_in_levels.values.squeeze(), lags=40,
    ax2 = fig.add_subplot(212)
    fig = sm.graphics.tsa.plot_pacf(TS_in_levels, lags=40, ax=ax2)
    #plt.savefig(asset_class + '_FAC_levels.pdf')
    plt.show()
```



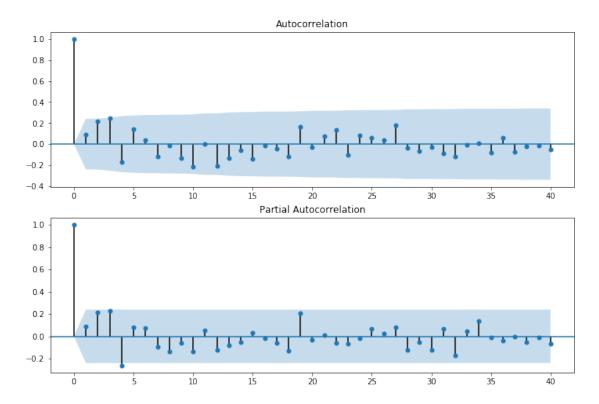
1.3 Fato 2 - Série de Preços, em nível, não rejeita a hipótese nula de raiz unitária

Confirmado. A partir resultado do teste de Dickey-Fuller, não podemos rejeitar a hipótese nula de raiz unitária

```
In [6]: # Fato 2 - serie dos preços nao rejeita hip raiz unitaria
                                   from statsmodels.tsa.stattools import adfuller
                                  unit_root_test = adfuller(TS_in_levels)
                                  test_out = pd.Series(unit_root_test[0:4], index = ['Test Statistic','p-valuest_out = pd.Series(unit_root_test[0:4], index = pd.Series(unit_root_test[0:4], 
                                  print('Results of Dickey-Fuller Test:')
                                  for key, value in unit_root_test[4].items():
                                                   test_out['Critical Value (%s)' %key] = value
                                  print(test_out)
Results of Dickey-Fuller Test:
Test Statistic
                                                                                                                                           1.955019
p-value
                                                                                                                                          0.998612
#Lags Used
                                                                                                                                          0.000000
Number of Observations Used
                                                                                                                                      67.000000
Critical Value (1%)
                                                                                                                                      -3.531955
Critical Value (5%)
                                                                                                                                      -2.905755
Critical Value (10%)
                                                                                                                                     -2.590357
dtype: float64
```

1.4 Fato 3 - FAC e FACP dos retornos é igual a zero

Confirmado. Nenhum dos lags nas FAC e FACP são estatiscamente significantes.

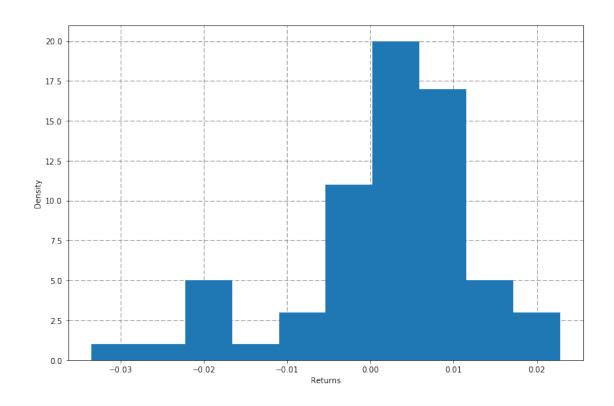


1.5 Fato 4 - Média dos retornos é positiva

Não confirmado. A média dos retornos estimada foi de 0.0014, mas com estatística t de 0.13, ou seja, estatisticamente igual a zero.

```
In [8]: # Fato 4 - media dos retornos > 0
for asset_class in EReturns.columns:
```

```
returns_summary = TS_in_returns.describe()
            print('Mean = %f' %returns_summary[1])
            print('Std dev = %f' %returns_summary[2])
            t_stat = returns_summary[1] / returns_summary[2]
            print('T-statistc = %f' %t_stat)
            fig = plt.figure(figsize = (12, 8))
            ax = fig.add_subplot(111)
            fig = plt.hist(TS_in_returns, zorder = 3)
            plt.xlabel('Returns')
            plt.ylabel('Density')
            plt.grid(color = 'gray', linestyle = 'dashed', zorder = 0)
            #plt.savefig(asset_class + '_returns_histogram.pdf')
            plt.show()
Mean = 0.001438
Std dev = 0.010956
T-statistc = 0.131249
```



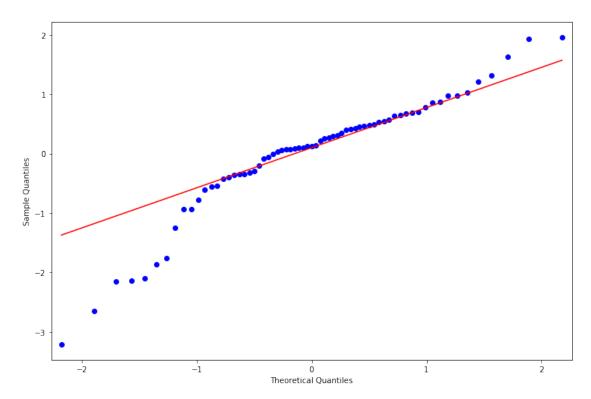
1.6 Fato 5 - A distribuição dos retornos tem "caudas largas"

Confirmado. Observando-se o qqplot, percebos que as "caudas" são mais largas que a de uma distribuição Normal.

```
In [9]: # Fato 5 - caudas largas

for asset_class in EReturns.columns:

fig = plt.figure(figsize=(12, 8))
    ax = fig.add_subplot(111)
    fig = qqplot(TS_in_returns, line='q', ax=ax, fit=True)
    #plt.savefig(asset_class + '_returns_qqplot.pdf')
    plt.show()
```



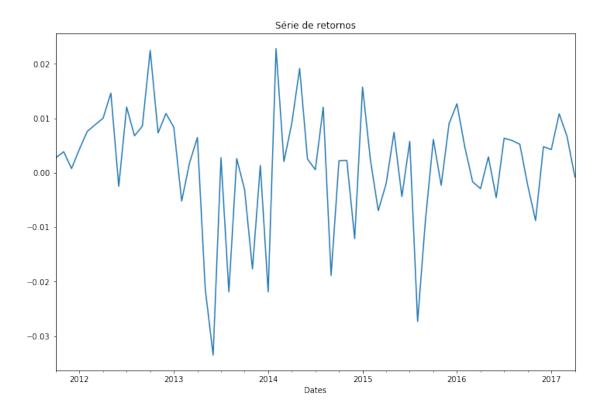
1.7 Fato 6 - A série de retornos apresenta clusters de volatilidade

Confirmado. Temos que pelo menos um dos coeficientes, α ou β , são estatistamente significantes, indicando que há clusters de volatilidade. No caso, temos que β é significante.

```
#plt.savefig(asset_class + 'returns_plot.pdf')
plt.show()

# modelo GARCH(1, 1) para testar o cluster de volatilidade
from arch import arch_model

garch = arch_model(TS_in_returns, p = 1, q = 1)
res = garch.fit(update_freq = 5)
print(res.summary())
res.plot()
```



Optimization terminated successfully. (Exit mode 0)

Current function value: -209.091961969

Iterations: 3

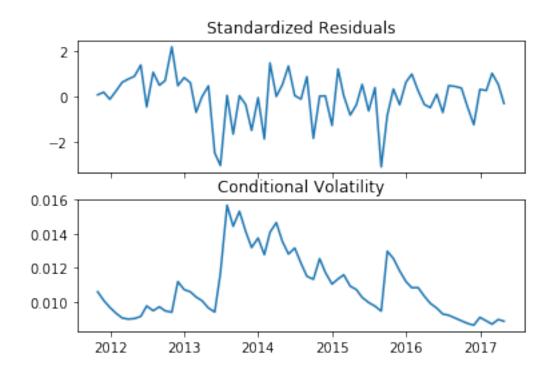
Function evaluations: 41 Gradient evaluations: 3

Constant Mean - GARCH Model Results

Dep. Variable: DebenturesIPCA R-squared: -0.001
Mean Model: Constant Mean Adj. R-squared: -0.001
Vol Model: GARCH Log-Likelihood: 209.092
Distribution: Normal AIC: -410.184

Method:	Maximum Likelihood				-401.365			
				Observation	s: 67			
Date:	Thu, Jun 01 2017			Residuals:	63			
Time:	00:08:22			<pre>fodel:</pre>	4			
	Mean Model							
	coef	std err	t 	P> t	95.0% Conf. Int.			
mu	1.7998e-03		1.299 latility Mo		[-9.167e-04,4.516e-03]			
	coef	std err	======== t 	P> t 	95.0% Conf. Int.			
omega alpha[1] beta[1]	1.1826e-05 0.1000 0.8000	0.111		0.000 0.369 1.940e-13	[1.183e-05,1.183e-05] [-0.118, 0.318] [0.587, 1.013]			

Covariance estimator: robust



1.8 Fato 7 - Maior volatilidade na abertura pós fins-de-semana

Confirmado. Foi feito um caso mais genérico criando-se uma dummy para indicar quando a diferença entre os pontos fosse maior que 1 dia. Rodando-se a regressão dos retornos ao quadrado

nos retornos ao quadrado de um período anterior, com o termo de interação dessa dummy com os retornos de lag 1, temos que o coeficiente no termo de interação é significativo, indicando a presença do fenômeno.

In [11]: #Fato 7 - maior volatilidade na abertura do fds

```
for asset_class in EReturns.columns:
          TS_in_returns_daily = EReturns_daily[asset_class].dropna()
          TS_{in}returns_daily_2 = TS_{in}returns_daily.apply(lambda x: x**2)
          lag_return = TS_in_returns_daily_2.shift()
          days_diff = TS_in_returns_daily_2.index.to_series().diff().dt.days
          daily_returns_2_df = pd.DataFrame(TS_in_returns_daily_2)
          daily_returns_2_df['lagged_return'] = lag_return.dropna()
          daily_returns_2_df['days_diff'] = np.where(days_diff > 1, 1, 0)
          daily_returns_2_df['return'] = TS_in_returns_daily
      import statsmodels.formula.api as smf
      reg_7 = smf.ols(formula = 'DebenturesIPCA ~ lagged_return + lagged_return
      reg_7.summary()
Out[11]: <class 'statsmodels.iolib.summary.Summary'>
                            OLS Regression Results
      ______
      Dep. Variable: DebenturesIPCA R-squared:
      Model:
                               OLS Adj. R-squared:
      Method:
                        Least Squares F-statistic:
      Date:
                     Thu, 01 Jun 2017 Prob (F-statistic):
                                                           1.11
                            00:08:23 Log-Likelihood:
      Time:
                                                             11
                                                          -2.316
      No. Observations:
                                1314
                                     AIC:
      Df Residuals:
                                1310 BIC:
                                                          -2.313
      Df Model:
      Covariance Type:
                           nonrobust
       ______
                             coef std err
                                           t
                                                   P>|t|
       ______
                         5.503e-06 1.19e-06
                                            4.616
      Intercept
                                                      0.000
                           0.3752 0.027
                                                     0.000
      lagged_return
                                            13.826
      days_diff
                         3.076e-06 2.35e-06
                                            1.309
                                                      0.191
      lagged_return:days_diff -0.2842 0.088 -3.240 0.001
       ______
                             2239.151 Durbin-Watson:
      Omnibus:
                               0.000 Jarque-Bera (JB): 2301173
      Prob(Omnibus):
                              11.031 Prob(JB):
      Skew:
                             206.823 Cond. No.
                                                            9.26
      Kurtosis:
       ______
```

- [1] Standard Errors assume that the covariance matrix of the errors is con-
- [2] The condition number is large, 9.26e+04. This might indicate that then strong multicollinearity or other numerical problems.

1.9 Fato 9 - Leverage effect

Não confirmado. Rodou-se uma regressão semelhante a do Fato 7, mas a dummy indica retornos negativos. O termo de interação não é estatisticamente significante.

```
In [12]: # Fato 9 - leverage effect
                     for asset_class in EReturns.columns:
                             monthly_returns_df = pd.DataFrame()
                              monthly_returns_df['returns'] = TS_in_returns
                             monthly_returns_df['return_square'] = TS_in_returns_2
                             monthly_returns_df['lagged_return'] = TS_in_returns.shift()
                             monthly_returns_df['lagged_return_square'] = TS_in_returns_2.shift()
                             monthly_returns_df['neg_return'] = np.where(monthly_returns_df['lagged')
                     reg_9 = smf.ols(formula = 'return_square ~ lagged_return_square + la
                     reg_9.summary()
Out[12]: <class 'statsmodels.iolib.summary.Summary'>
                                                                                     OLS Regression Results
                     ______
                    Dep. Variable:
                                                                           return_square R-squared:
                    Model:
                                                                                                    OLS Adj. R-squared:
                    Method:
                                                                          Least Squares F-statistic:
                                                                                                                                                                                            0
                                                                   Thu, 01 Jun 2017 Prob (F-statistic):
                    Date:
                    Time:
                                                                                        00:08:23 Log-Likelihood:
                    No. Observations:
                                                                                                      66 AIC:
                    Df Residuals:
                                                                                                       62
                                                                                                                 BIC:
                    Df Model:
                    Covariance Type:
                                                                                   nonrobust
                     ______
                                                                                                            coef
                                                                                                                             std err
                                                                                                                                                                                       P> | t
                                                                                                                                                                     t.
                     ______
                                                                                                       0.0001 3.71e-05
                                                                                                                                                            3.602
                                                                                                                                                                                       0.00
                     Intercept
                     lagged_return_square
                                                                                                     -0.2118
                                                                                                                             0.259
                                                                                                                                                         -0.818
                                                                                                                                                                                       0.41
                                                                                            -3.317e-05 6.63e-05
                                                                                                                                                         -0.500
                                                                                                                                                                                       0.61
                     neg_return
                     lagged_return_square:neg_return 0.3712 0.300
                                                                                                                                                                                       0.22
                                                                                                                                                           1.236
```

4 (

211

1.40

Prob(Omnibus):

Skew:

53.354 Durbin-Watson:

2.474 Prob(JB):

0.000 Jarque-Bera (JB):

Kurtosis: 10.232 Cond. No. 1.63

Warnings:

- [1] Standard Errors assume that the covariance matrix of the errors is con
- [2] The condition number is large, 1.61e+04. This might indicate that the strong multicollinearity or other numerical problems.

1.10 Regressões de Longo Prazo

O spread de crédito será a variável preditiva de retorno de Debêntures atreladas ao IPCA. Como a série de Debentures é relativamente pequena e recente (desde 2011), usaremos os retornos mensais para obter-se uma amostra maior. A regressão será do tipo

ExcessoRetornoIDAIPCA = a + b.spreadCredito + erro

```
In [13]: # importing credit spread series - fonte: IPEADATA

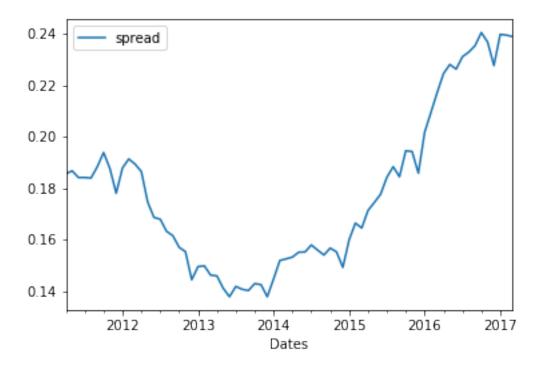
spread_series = pd.ExcelFile(os.path.join(pathname, 'spread_credito.xls'))

spread = pd.DataFrame()

for asset_class in spread_series.sheet_names:
    #print(asset_class)
    df = spread_series.parse(asset_class, index_col = 0, skiprows = 1)
    df.columns = [asset_class]
    df.index.name = 'Dates'
    spread = pd.concat([spread, df], join = 'outer', axis = 1)

spread.plot()

# forward fill da series
TS_in_returns = pd.concat([TS_in_returns, spread], axis = 1).fillna(method)
```



In [14]: # criando serie de retornos acumulados

```
Returns = AllAssetClasses.pct_change(1)
EReturns = pd.DataFrame()
for asset_class in Returns.columns:
    EReturns[asset_class] = Returns[asset_class] - Returns['CDI']
for i in range (12, 61, 12):
    Returns = AllAssetClasses.pct_change(i)
    EReturns = pd.DataFrame()
    for asset_class in Returns.columns:
        EReturns[asset_class] = Returns[asset_class] - Returns['CDI']
    TS_in_returns['cum' + str(i)] = EReturns['DebenturesIPCA']
# rodando regressao
reg_lp_12 = smf.ols(formula = 'cum12 ~ spread', data = TS_in_returns).fit
reg_lp_24 = smf.ols(formula = 'cum24 ~ spread', data = TS_in_returns).fit
req_lp_36 = smf.ols(formula = 'cum36 ~ spread', data = TS_in_returns).fit
reg_lp_48 = smf.ols(formula = 'cum48 ~ spread', data = TS_in_returns).fit
reg_lp_60 = smf.ols(formula = 'cum60 ~ spread', data = TS_in_returns).fit
```

In [15]: from statsmodels.iolib.summary2 import summary_col

See the caveats in the documentation: http://pandas.pydata.org/pandas-docs/stable/

A value is trying to be set on a copy of a slice from a DataFrame

res.ix[:, 0][idx] = res.ix[:, 0][idx] + '*'
C:\Anaconda3\lib\site-packages\statsmodels\iolib\summary2.py:376: SettingWithCopyWa
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: http://pandas.pydata.org/pandas-docs/stable/ires.ix[:, 0][idx] = res.ix[:, 0][idx] + '*'

	1y	2y	====== Зу 	 4y	5y
Intercept				0.49***	
spread	0.01 (0.21)			-2.19*** (0.37)	
N	56	44	32	20	8
R2	0.00	0.03	0.02	0.66	0.00

Standard errors in parentheses.

* p<.1, ** p<.05, ***p<.01

Observa-se um R2 de 66% para os retornos de 4 anos além dos coeficientes significantes à menos de 1%. O fato não é observado para os demais casos. Esperava-se encontrar tambem um R2 alto para os retornos de 5 anos, mas não foi o caso - devido a poucas observações na amostra. Devemos tomar cuidado, no entanto, com os resultados devido ao pequeno tamanho da amostra por tratar-se de uma série recente.

In []: